



Katedra za računarstvo

MAS: Računarstvo i informatika, Veštačka inteligencija i mašinsko učenje
Inteligentni sistemi: Projektovanje i implementacija AI MVP

FakeAd

AI sistem za detekciju lažnih oglasa
Tehnička dokumentacija MVP

Tim:

Ljiljana Stojičić 2136
Iva Blagojević 2137

Izveštaj 1: Predlog projekta

Akronim i naziv

Akronim: FakeAd

Naziv rešenja: FakeAd - AI sistem za detekciju lažnih oglasa za posao.

Kratak opis

FakeAd je inteligentni sistem koji na osnovu teksta oglasa za posao procenjuje verovatnoću da je oglas lažan i tu procenu obrazlaže korisniku. Sistem kombinuje klasifikator zasnovan na mašinskom učenju, koji donosi odluku, i veliki jezički model, koji generiše objašnjenje u obliku konkretnih indikatora prevare. Razvijen je kao minimalni održiv proizvod (MVP).

AI tehnologije (plan)

- Obrada prirodnog jezika (NLP): tokenizacija, čišćenje i vektorizacija teksta oglasa.
- Mašinsko učenje za klasifikaciju teksta: referentni model i kontekstualni klasifikator.
- Analiza obrazaca i ključnih karakteristika oglasa (dužina teksta, nedostajuća polja, indikativne reči).
- Korišćenje postojećih (velikih) jezičkih modela za procenu pouzdanosti teksta i generisanje objašnjenja.

Tim

- Ljiljana Stojičić 2136
- Iva Blagojević 2137

Izveštaj 2: Definisanje problema

Predlog rešenja

Onlajn oglasi za posao postali su osnovni kanal povezivanja poslodavaca i kandidata, ali su istovremeno postali i meta zloupotreba. Lažni oglasi (engl. employment scam) osmišljeni su da podražavaju legitimne - obećavaju nerealno visoku zaradu za mali angažman, stvaraju osećaj hitnosti i traže uplatu ili osetljive lične podatke pre zasnivanja radnog odnosa. Ručna provera velikog broja oglasa nije održiva.

FakeAd ovaj problem rešava automatski. Korisnik unosi tekst oglasa, a sistem procenjuje verovatnoću prevare i generiše objašnjenje - listu konkretnih „crvenih signala” i kratko obrazloženje razumljivo čoveku. Za razliku od pukog klasifikatora koji vraća samo oznaku, FakeAd donosi odluku i objašnjava je, čime korisniku pomaže da samostalno proceni oglas.

Ciljna grupa

Primarna ciljna grupa su kandidati koji pretražuju oglase za posao i žele brzu proveru sumnjivih ponuda, kao i platforme i portali za zapošljavanje koji bi automatski filtrirali sumnjive oglase pre objave. Jedini preduslov za korišćenje jeste dostupan tekst oglasa.

Konkurentske prednosti

- **Hibridni pristup:** diskriminativni klasifikator donosi odluku, a generativni jezički model je objašnjava - spoj tačnosti i objašnjivosti.
- **Objašnjivost:** sistem ne vraća samo procenat, već i konkretne razloge (crvene signale), što gradi poverenje korisnika.
- **Prepoznavanje suptilnih prevara:** kontekstualni model hvata i pažljivo sastavljene prevare bez očiglednih ključnih reči.
- **Transparentnost:** prikazuju se procene oba modela (referentnog i kontekstualnog), pa je odluka proverljiva.

Osnovne funkcionalnosti

- Unos teksta oglasa za analizu.
- Pretprocesiranje teksta (uklanjanje HTML-a, normalizacija, spajanje polja).
- Procena verovatnoće prevare pomoću dva modela (referentnog i kontekstualnog).
- Generisanje objašnjenja: lista crvenih signala i tekstualno obrazloženje na srpskom.
- Prikaz rezultata kroz veb-interfejs: procena, verovatnoće modela i objašnjenje.

AI zasnovane funkcionalnosti

Srž sistema čine tri međusobno povezane AI komponente:

- **Referentni klasifikator (TF-IDF + logistička regresija):** brz i interpretabilan model koji služi kao merna osnova i kao druga procena u aplikaciji.
- **Kontekstualni klasifikator (DistilBERT):** fino podešeni jezički model koji razume kontekst reči i donosi glavnu odluku o verovatnoći prevare.

- **Sloj za objašnjenje (veliki jezički model):** za sumnjiv oglas generiše konkretne crvene signale i obrazloženje; ne donosi odluku, već je objašnjava.

Izveštaj 3: Izbor tehnologija i skupova podataka

Tehnologije

Komponenta	Tehnologija	Svrha
Programski jezik	Python 3	Svi AI/ML moduli: pretprocesiranje, treniranje, inferens.
Trening okruženje	Google Colab (GPU)	Besplatan GPU (T4) za fino podešavanje DistilBERT-a.
Razvoj aplikacije	VS Code	Lokalni razvoj i pokretanje veb-aplikacije.
Korisnički interfejs	Streamlit	Veb UI: unos oglasa, prikaz procene i objašnjenja.
LLM platforma	Groq	Pristup velikom jezičkom modelu za generisanje objašnjenja.
Verzionisanje	Git + GitHub	Kontrola verzija i saradnja u timu.

Tabela 1. Razvojne tehnologije i alati.

AI tehnologije i biblioteke


Biblioteka	Uloga	Detalji
scikit-learn	Referentni model	TF-IDF (max_features=20000, ngram (1,2), min_df=5), logistička regresija, metrike.
Hugging Face Transformers	Kontekstualni model	distilbert-base-uncased, fino podešavanje za binarnu klasifikaciju.
PyTorch	Računski okvir	Backend za treniranje DistilBERT-a; ponderisana funkcija gubitka.
Groq SDK	LLM sloj	Poziv modela openai/gpt-oss-20b, odgovor u JSON formatu.
pandas / NumPy	Obrada podataka	Učitavanje i priprema CSV skupa, obrada polja.

Tabela 2. Biblioteke za AI funkcionalnost.

Skup podataka

Za obuku i evaluaciju korišćen je EMSCAD (Employment Scam Aegean Dataset), poznat i kao „Real or Fake Job Posting Prediction”. Skup sadrži 17.880 realnih oglasa za posao sa 18 atributa: tekstualna polja (naslov, opis kompanije, opis posla, zahtevi, beneficije) i meta-podatke (rad na daljinu, prisustvo logotipa, tip zaposlenja i drugo). Ciljni atribut označava da li je oglas lažan. Skup je javno dostupan pod licencom javnog domena (CC0).

Ključna karakteristika je izražena neravnoteža klasa: od 17.880 oglasa, samo 866 (4,84%) je lažno (Slika 1). Ovo direktno utiče na izbor metrika i strategiju treniranja.



Slika 1. Raspodela klasa u skupu EMSCAD.

Pre izbora razmotreno je više javno dostupnih skupova. Kriterijumi su bili: prisustvo obe klase, dovoljna količina podataka, dostupnost teksta, jasna licenca i uporedivost sa literaturom.


Skup podataka	Veličina	Obe klase	Jezik	Ocena
EMSCAD (Real/Fake Job Posting)	17.880 ($\approx 4,8\%$ lažnih)	Da	Eng.	Izabran
Fake/Scam Job Postings	10.000 (100% lažnih)	Ne	Eng.	Neprikladan sam
EMSCAD podskup (US/eng.)	≈ 10.593 ($\approx 7\%$ lažnih)	Da	Eng.	Izveden, manji
Amazon Fraud Benchmark	Agregat (uklj. isti skup)	Da	Eng.	Šira namena
LIAR (lažne vesti)	12.800 izjava	Da	Eng.	Pogrešan domen

Tabela 3. Razmotreni skupovi podataka i obrazloženje izbora.

Izveštaj 4: Razvoj MVP

Arhitektura sistema

FakeAd je implementiran kao Streamlit aplikacija koja direktno poziva Python module za pretprocesiranje i inferens, bez HTTP sloja. Treniranje modela obavljeno je odvojeno, u okruženju Google Colab, a istrenirani modeli se učitavaju u aplikaciju. Objedinjeni tok obrade prikazan je na Slici 2.



Slika 2. Arhitektura sistema FakeAd.

Modul	Odgovornost
Pretprocesiranje	Uklanjanje HTML-a, normalizacija razmaka, spajanje tekstualnih polja, mapiranje labele (t/f → 1/0).
Referentni model	TF-IDF vektorizacija + logistička regresija; sačuvan kao baseline.joblib.
Kontekstualni model	Fino podešeni DistilBERT; sačuvan u folderu fakead_model/.
LLM sloj	Poziv Groq modela; generisanje crvenih signala i objašnjenja u JSON formatu.
Korisnički interfejs	Streamlit aplikacija (app.py): unos oglasa, prikaz procene oba modela i objašnjenja.

Tabela 4. Moduli sistema i njihove odgovornosti.

Pipeline (tok obrade po zahtevu)

Aplikacija se pokreće komandom `streamlit run app.py` i dostupna je lokalno na `http://localhost:8501`. Pri svakom kliku na „Analiziraj” izvršavaju se sledeći koraci:

1. Unos: korisnik unosi tekst oglasa.
2. Pretprocesiranje: uklanjanje HTML oznaka i normalizacija teksta.
3. Referentna predikcija: TF-IDF vektorizacija → logistička regresija → verovatnoća prevare.
4. Kontekstualna predikcija: tokenizacija → DistilBERT → verovatnoća prevare.
5. Prikaz procene: verovatnoće oba modela i oznaka (sumnjiv / verovatno legitiman).
6. Objašnjenje (ako je LLM sloj uključen): Groq generiše crvene signale i obrazloženje u JSON formatu.
7. Prikaz objašnjenja: lista crvenih signala i tekstualno obrazloženje.

Rešavanje neravnoteže klasa

Zbog izražene neravnoteže (4,84% lažnih), primenjene su tri mere. U referentnom modelu korišćen je parametar uravnoteženih težina klasa. U DistilBERT-u je implementirana ponderisana funkcija gubitka (weighted cross-entropy), gde su klase ponderisane obrnuto srazmerno zastupljenosti, pa model greške na retkoj klasi kažnjava jače. Podela na trening i test skup je stratifikovana, čime je očuvan isti odnos klasa. SMOTE nije primenjen na DistilBERT jer radi nad numeričkim vektorima, dok kontekstualni model radi nad tekstom; ekvivalent (sintetičko generisanje lažnih oglasa) naveden je kao budući rad.

Ključne tehničke odluke i ispravke

Tokom razvoja rešeno je nekoliko tehničkih problema:

Problem	Opis i rešenje
Konflikt biblioteka (pyarrow/datasets)	ValueError pri importu u Colab-u zbog nekompatibilnih verzija. Rešenje: usklađivanje verzija i restart runtime-a.
torch nije importovan	NameError posle restarta runtime-a. Rešenje: dodat import torch u ćeliju treninga.
Prazan baseline.joblib	EOFError jer model nije bio u memoriji posle restarta. Rešenje: ponovno treniranje i provera veličine fajla pre preuzimanja.
GitHub limit veličine fajla	model.safetensors (255 MB) prelazi limit od 100 MB. Rešenje: model i podaci dodati u .gitignore, na repozitorijum ide samo kod.
Prikaz notebook-a na GitHub-u	Greška „metadata.widgets” pri renderovanju. Rešenje: uklanjanje bloka widgets iz .ipynb metapodataka.
Povučeni Groq modeli	Modeli Llama 3.1/3.3 povučeni sa platforme. Rešenje: prelazak na openai/gpt-oss-20b.
Nevalidna vrednost LLM procene	Model je vraćao proizvoljan tekst umesto očekivane oznake. Rešenje: eksplicitno navedene dozvoljene vrednosti u upitu.

Tabela 5. Rešeni tehnički problemi tokom razvoja.

Pored ispravki, donete su i sledeće dizajnerske odluke:

- DistilBERT umesto punog BERT-a -bolji odnos tačnosti i resursa za MVP (staje u besplatni GPU, brz trening).
- TF-IDF baseline razvijen prvi -kao merna osnova pre složenog modela (standardna ML metodologija).
- Streamlit umesto React/FastAPI -najbrži put do funkcionalnog MVP-a; produkciona verzija bi koristila odvojeni backend.
- max_length=256 za DistilBERT -kompromis između brzine treniranja i pokrivenosti dužih oglasa.
- LLM koristi se samo za objašnjenje, ne za odluku -zbog determinizma i pouzdanosti klasifikacije.
- Groq API ključ se unosi u aplikaciji (sidebar), ne u kodu -radi bezbednosti.

Izveštaj 5: Testiranje i provera funkcionalnosti


Evaluacija modela

Modeli su evaluirani na test skupu (20% podataka, stratifikovano). Zbog neravnoteže, umesto tačnosti korišćene su preciznost, odziv i F1 na klasi lažnih oglasa i PR-AUC. Rezultati su dati u Tabelama 6 i 7.


Model	Preciznost	Odziv	F1	PR-AUC
TF-IDF + logistička regresija	0,766	0,908	0,831	0,921
DistilBERT	0,924	0,844	0,882	0,934

Tabela 6. Rezultati modela na klasi „lažno”.

Prelaskom sa referentnog na kontekstualni model preciznost je porasla sa 0,766 na 0,924, dok je odziv blago opao. Matrice konfuzije (Slika 4) pokazuju da je broj lažnih uzbuna smanjen sa 48 na 12, dok je broj propuštenih prevara porastao sa 16 na 27.



Slika 3. Poređenje modela na klasi „lažno”.



Slika 4. Matrice konfuzije: referentni model (levo) i DistilBERT (desno).

End-to-end testovi

Sistem je proveren na tri reprezentativna oglasa -od očigledno lažnog do jasno legitimnog - kako bi se potvrdilo ponašanje u celom rasponu:

Test oglas	DistilBERT	Baseline	LLM procena	Komentar
Očigledno lažan (rad od kuće, nerealna zarada, uplata unapred, samo WhatsApp)	100%	93%	verovatno lažno	Svi crveni signali prepoznati.
Suptilno lažan (uredan opis, ali traži matični broj i skenirani dokument pre posla)	100%	67%	verovatno lažno	Uhvaćena suptilna prevara bez očiglednih ključnih reči.
Legitiman (jasan opis firme, realni uslovi i zahtevi)	0%	22%	verovatno pravo	Nema lažne uzbune na pravom oglasu.

Tabela 7. Rezultati end-to-end testova.

Sistem je ispravno rangirao sva tri slučaja. Posebno je značajan drugi slučaj: suptilna prevara je prepoznata iako nema grube signale, a LLM sloj je kao ključne razloge naveo traženje ličnih podataka pre zaposlenja, nerealnu platu i hitnost. Na legitimnom oglasu sistem nije prijavio nijedan indikator.

Poznate limitacije

- Jezik i domen: EMSCAD čine oglasi na engleskom jeziku; primena na srpske oglase je pravac budućeg rada (npr. model BERTić).
- Neravnoteža klasa: mali broj lažnih primera ostaje izazov -model propušta deo suptilnih prevara (nešto niži odziv).
- Nedeterminizam LLM sloja: objašnjenja mogu varirati između poziva; sloj je pomoćni i ne utiče na klasifikaciju.
- Jedan skup podataka: evaluacija je izvršena na jednom skupu; validacija na nezavisnim podacima ojačala bi zaključke.
- Fiksni prag odlučivanja: prag je postavljen na 0,5; podešavanjem bi se mogao menjati kompromis preciznost/odziv.
- LLM sloj zahteva internet i Groq API ključ za generisanje objašnjenja.